

UNIVERSIDAD MAYOR DE SAN ANDRÉS

Facultad de Ciencias Puras y Naturales — Carrera de Informática



INFORME DE PROYECTO

Materia: Machine Learning

Identificación y Caracterización de Zonas Gastronómicas en la Ciudad de La Paz mediante Clustering Geoespacial con HDBSCAN

Estudiante: Alexandra Cristal Salazar Gisberth

Docente: M.Sc. Menfy Morales Ríos

La Paz, Bolivia — 2026

Índice de Contenidos

Contenido

Índice de Contenidos	2
1. Resumen.....	4
2. Planteamiento del Problema y Objetivos	5
2.1. Descripción del Problema	5
2.2. Objetivos	5
Objetivo General	5
Objetivos Específicos.....	5
3. Dataset: Recolección y Descripción	6
3.1. Proceso de Scraping con SerpAPI	6
3.2. Estructura del Dataset Raw	6
3.3. Análisis Exploratorio (EDA)	7
4. Preprocesamiento e Ingeniería de Features	8
4.1. Limpieza y Tratamiento de Valores Faltantes	8
4.2. Transformaciones Aplicadas	8
4.3. Reducción Dimensional: PCA	9
5. Métodos de Clustering Evaluados	10
5.1. KMeans.....	10
Fundamento teórico	10
Aplicación y resultados	10
5.2. DBSCAN	11
Fundamento teórico	11
Aplicación y resultados	12
5.3. HDBSCAN (Modelo Seleccionado).....	12
Fundamento teórico	12
Aplicación y parámetros.....	13
Resultados HDBSCAN	13
6. Reducción Dimensional para Visualización: UMAP y t-SNE	15
6.1. UMAP (Uniform Manifold Approximation and Projection)	15
6.2. t-SNE (t-Distributed Stochastic Neighbor Embedding)	15
7. Comparación de Algoritmos y Justificación de HDBSCAN	16
7.1. Métricas de Validez Interna	16
7.2. Tabla Comparativa.....	16
7.3. Por Qué HDBSCAN es el Mejor Modelo para este Problema	17

8. Resultados: Zonas Gastronómicas Descubiertas	19
8.1. Descripción del Dataset Resultante	19
8.2. Perfil de Cada Zona	19
8.3. Validación del Mapa Interactivo	21
9. Dashboard Interactivo (Streamlit)	23
10. Conclusiones	24

1. Resumen

El presente trabajo aplica técnicas de **aprendizaje no supervisado** para identificar y caracterizar zonas gastronómicas en la ciudad de La Paz, Bolivia. A partir de un dataset de **626 establecimientos** recolectado mediante la API de Google Maps (SerpAPI), se construyó una matriz de features geoespaciales y de calidad que incluye coordenadas geográficas, densidad vecinal a 500 m, rating normalizado, popularidad (log de reseñas) y nivel de precios. Se evaluaron tres algoritmos de clustering: KMeans, DBSCAN y HDBSCAN. Tras comparar métricas de validez interna (Silhouette Score y Calinski-Harabasz Index), se seleccionó **HDBSCAN** como modelo principal por obtener el mayor Silhouette Score (0.410), por su capacidad de detectar clusters de forma arbitraria sin requerir el número de zonas a priori, y por manejar honestamente el ruido geoespacial propio de una ciudad con alta dispersión comercial. El modelo identificó **7 zonas gastronómicas diferenciadas**, visualizadas mediante UMAP y proyectadas en un mapa interactivo Folium. Los resultados se integran en un dashboard Streamlit para exploración interactiva.

Palabras clave: *clustering, HDBSCAN, aprendizaje no supervisado, gastronomía, geoespacial, La Paz Bolivia, UMAP, SerpAPI.*

2. Planteamiento del Problema y Objetivos

2.1. Descripción del Problema

La ciudad de La Paz cuenta con una oferta gastronómica amplia y heterogénea, distribuida de manera no uniforme en su territorio. Sin embargo, no existe un mapa estructurado ni una caracterización sistemática de las zonas donde se concentran ciertos perfiles de establecimientos (por ejemplo, zonas de alta densidad y bajo precio versus zonas de nicho y alta calidad). Esta falta de información dificulta tanto la toma de decisiones de emprendedores del sector como el análisis urbano-comercial de la ciudad.

El problema central es:

¿Es posible identificar automáticamente, sin etiquetas previas, zonas gastronómicas diferenciadas en La Paz a partir de características geoespaciales y de calidad de los establecimientos?

Este problema corresponde a un escenario de **aprendizaje no supervisado**: no se dispone de etiquetas de zona predefinidas, y el objetivo es que el algoritmo descubra estructura latente en los datos sin supervisión externa.

2.2. Objetivos

Objetivo General

Identificar y caracterizar zonas gastronómicas en la ciudad de La Paz, Bolivia, mediante algoritmos de clustering aplicados a datos geoespaciales y de calidad recolectados de Google Maps.

Objetivos Específicos

- Construir un dataset representativo de establecimientos gastronómicos paceños mediante scraping automatizado con SerpAPI.
- Diseñar una matriz de features que capture las dimensiones geoespaciales, de densidad y de calidad de cada establecimiento.
- Evaluar y comparar tres algoritmos de clustering (KMeans, DBSCAN, HDBSCAN) mediante métricas de validez interna.
- Justificar la selección de HDBSCAN como modelo principal en función de sus fundamentos teóricos y resultados empíricos.
- Visualizar las zonas descubiertas mediante proyecciones UMAP, t-SNE y mapas interactivos Folium.
- Integrar los resultados en un dashboard interactivo desarrollado en Streamlit.

3. Dataset: Recolección y Descripción

3.1. Proceso de Scraping con SerpAPI

Los datos fueron recolectados mediante la **API de Google Maps** a través del servicio SerpAPI, que provee acceso programático a los resultados de Google Maps sin necesidad de web scraping directo. Se definieron **12 términos de búsqueda** (queries) diseñados para cubrir distintos tipos de establecimientos y distintas áreas de la ciudad:

- Restaurantes La Paz Bolivia
- Cafeterías La Paz Bolivia
- Comida rápida La Paz Bolivia
- Salteñerías La Paz Bolivia
- Mercado comida La Paz Bolivia
- Pizzería / Bar / Heladerías / Anticuchería La Paz Bolivia
- Desayuno / Almuerzo económico / Cena La Paz Bolivia

Para cada query se obtuvieron hasta **3 páginas de resultados** (60 lugares por query), con un total de **626 registros raw**. Tras deduplicación por coordenadas geográficas redondeadas a 5 decimales (~1 metro de precisión), se obtuvieron **427 lugares únicos** en el dataset limpio principal, aunque el pipeline completo conservó los 626 para análisis de features.

3.2. Estructura del Dataset Raw

El dataset raw (dataset_lapaz_raw.csv) contiene las siguientes variables:


Variable	Tipo	Descripción
Nombre	String	Nombre del establecimiento
Tipo	String	Categoría según Google Maps (ej. Restaurante, Cafetería)
Lat	Float	Latitud geográfica (WGS84)
Lon	Float	Longitud geográfica (WGS84)
Rating	Float	Calificación promedio (escala 1.0 – 5.0)
n_resenas	Integer	Número total de reseñas de usuarios
Precio	String	Rango de precios textual (ej. Bs 40-100, \$\$)
Direccion	String	Dirección postal del establecimiento
query_origen	String	Query de búsqueda que generó este registro

Tabla 1. Variables del dataset raw recolectado con SerpAPI.

3.3. Análisis Exploratorio (EDA)

El análisis exploratorio reveló las siguientes características del dataset:

- La categoría más frecuente es
 - **Restaurante** (353 establecimientos, 56.4 %), seguida de Otro (74), Cafetería (71), Heladería (48), Mercado (46) y Bar (34).
- El rating presenta una distribución sesgada a la derecha con una media de aproximadamente 4.3/5.0, lo que refleja el sesgo positivo típico de las plataformas de reseñas.
- Las reseñas siguen una distribución altamente asimétrica (log-normal): la mayoría de establecimientos tiene pocas reseñas, mientras que unos pocos superan las 1,000.
- Los precios fueron codificados desde texto libre (Bs 40-100, \$\$, Más de Bs 200) a valores numéricos mediante una función de extracción por expresiones regulares.
- Geográficamente, los establecimientos se concentran en el centro histórico (Sopocachi, Miraflores) y la zona sur (Calacoto, San Miguel), con dispersión hacia las laderas.



4. Preprocesamiento e Ingeniería de Features

4.1. Limpieza y Tratamiento de Valores Faltantes

- Rating faltante: imputado con la mediana del dataset (4.3). Este valor refleja la tendencia central sin ser afectado por outliers extremos.
- Número de reseñas: los valores faltantes se reemplazaron por 0 (sin reseñas registradas).
- Precio faltante: imputado con la mediana de precio_prom (~Bs 70).
- Los precios textuales fueron parseados con una función de expresiones regulares que extrae valores mínimo, máximo y promedio.

4.2. Transformaciones Aplicadas

Se construyó la siguiente matriz de features (X) con 6 dimensiones por establecimiento:

Feature	Transformación	Justificación
lat, lon	Sin transformación (escalado posterior)	Coordenadas geográficas — capturan posición espacial
densidad_500m	Conteo de vecinos en radio 500 m (Haversine)	Mide concentración de competidores en el entorno inmediato
rating_norm	$(\text{rating} - 1) / 4 \rightarrow$ rango $[0, 1]$	Normalización min-max sobre escala 1-5 de Google Maps
log_resenas	$\log(1 + n_resenas)$	Reduce skewness de la distribución de reseñas (log-normal)
precio_log	$\log(1 + \text{precio_prom})$	Reduce heteroscedasticidad del rango de precios en Bs

Tabla 2. Features construidas para el modelo de clustering.

La **densidad vecinal** se calculó mediante la distancia de Haversine (distancia geodésica sobre la superficie esférica de la Tierra), contando cuántos establecimientos del dataset caen dentro de un radio de 500 metros de cada punto. Este feature captura la competitividad y actividad gastronómica del entorno inmediato de cada lugar.

Finalmente, todas las features fueron estandarizadas con **StandardScaler** (media = 0, desviación estándar = 1), garantizando que ninguna variable domine el cálculo de distancias por diferencias de escala.


La variable **tipo** de establecimiento fue excluida del modelo de forma deliberada: al ser una variable categórica conocida a priori, incluirla equivaldría a supervisar parcialmente el proceso. En cambio, se reservó

como variable de validación post-hoc para verificar si los clusters descubiertos capturan información relevante sobre el tipo de negocio.

4.3. Reducción Dimensional: PCA

Antes de aplicar los algoritmos de clustering, se realizó una reducción dimensional mediante **Análisis de Componentes Principales (PCA)**. El análisis de varianza explicada acumulada indicó que **5 componentes principales** capturan el 90 % de la varianza total del dataset. Se conservaron estos 5 componentes para el clustering, logrando:

- Reducir el ruido de alta dimensionalidad que puede distorsionar las métricas de distancia en algoritmos basados en vecindad.
- Decorrelacionar las features, eliminando redundancia entre variables correlacionadas (ej. precio y rating tienden a correlacionar positivamente).
- Acelerar el cómputo de los algoritmos de clustering.



5. Métodos de Clustering Evaluados

5.1. KMeans

Fundamento teórico

KMeans es un algoritmo de particionamiento que divide el dataset en **k grupos mutuamente excluyentes** minimizando la inercia (suma de cuadrados de distancias intra-cluster). Dado un número k de clusters, el algoritmo:

1. Inicializa k centroides aleatoriamente (o con KMeans++, que mejora la inicialización).
2. Asigna cada punto al centroide más cercano (por distancia Euclidiana).
3. Recalcula los centroides como la media de los puntos asignados.
4. Repite los pasos 2-3 hasta convergencia.


La función objetivo que minimiza es:


$$J = \sum_i \sum_{x \in C_i} \|x - \mu_i\|^2$$

donde μ_i es el centroide del cluster i y la suma recorre todos los puntos x asignados a dicho cluster.

Aplicación y resultados

Se evaluaron valores de k de 2 a 12 mediante el **método del codo** (curva de inercia) y el **Silhouette Score**. El k óptimo resultó ser **k = 4**, con un Silhouette Score de 0.338. Si bien KMeans produjo clusters compactos y equilibrados, sus supuestos de esfericidad y tamaño similar de clusters lo limitan frente a la geometría irregular de los datos geoespaciales.





5.2. DBSCAN

Fundamento teórico

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) es un algoritmo basado en densidad que clasifica los puntos en tres categorías:

- tienen al menos min_samples vecinos dentro de un radio ϵ .


Tienen al menos **min_samples** vecinos dentro de un radio ϵ .

- Border points: están dentro del radio ϵ de un core point pero no son core ellos mismos.
- Noise points (ruido): no cumplen ninguna de las condiciones anteriores — son outliers.

A diferencia de KMeans, DBSCAN **no requiere especificar k** y puede detectar clusters de forma arbitraria. Sin embargo, es sensible a la elección de los parámetros ϵ y min_samples , y su desempeño se degrada en datasets con densidades variables.

Aplicación y resultados

El parámetro ϵ se estimó mediante el gráfico de k -distancias (distancia al 5° vecino más cercano, ordenada descendientemente). Con $\epsilon = 0.5$ y $\text{min_samples} = 10$, DBSCAN identificó únicamente **2 clusters**, marcando el 89 % de los puntos como ruido — un resultado claramente insatisfactorio para el objetivo del proyecto. Este comportamiento refleja la limitación fundamental de DBSCAN ante datos con densidades heterogéneas.



5.3. HDBSCAN (Modelo Seleccionado)

Fundamento teórico

HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise) es una extensión jerárquica de DBSCAN desarrollada por Campello, Moulavi y Sander (2013). Su innovación central es construir una **jerarquía de clusters** basada en densidad y extraer los clusters más estables en distintos niveles de densidad.

El algoritmo opera en los siguientes pasos:

5. Calcula la distancia de alcanzabilidad mutua (mutual reachability distance) entre pares de puntos:

$$d_mreach(a,b) = \max\{core_k(a), core_k(b), d(a,b)\}$$

donde $core_k(x)$ es la distancia al k-ésimo vecino más cercano de x y $d(a,b)$ es la distancia original entre los puntos.

6. Construye el árbol de expansión mínima (Minimum Spanning Tree) del grafo de distancias de alcanzabilidad mutua.
7. Convierte el MST en una jerarquía de clusters (dendrograma condensado), eliminando gradualmente aristas largas.
8. Calcula la estabilidad de cada cluster a lo largo de la jerarquía mediante la medida λ (lambda):

$$estabilidad(C) = \sum_{x \in C} (\lambda_death(x) - \lambda_birth(C))$$

9. Extrae los clusters de mayor estabilidad mediante el método EOM (Excess of Mass), seleccionando los que maximizan la suma de estabilidades en el árbol.
10. Los puntos que no pertenecen a ningún cluster estable se etiquetan como ruido (label = -1).

min_cluster_size: tamaño mínimo de un cluster válido. Controla la granularidad.

- min_samples: controla la robustez frente al ruido (similar al min_samples de DBSCAN).
- cluster_selection_method: 'eom' (Excess of Mass) para clusters de tamaño variable; 'leaf' para clusters más uniformes.

Aplicación y parámetros

Tras un proceso de ajuste de hiperparámetros, se seleccionaron los siguientes valores:

Parámetro	Valor	Justificación
min_cluster_size	10	Zona mínima con 10 establecimientos; evita micro-clusters espurios
min_samples	10	Alta robustez frente al ruido geoespacial
cluster_selection_method	eom	Permite zonas de distintos tamaños (más realista)
metric	euclidean	Distancia en espacio PCA estandarizado
prediction_data	True	Permite calcular probabilidades de pertenencia


Tabla 3. Hiperparámetros seleccionados para HDBSCAN.

Resultados HDBSCAN

El modelo identificó **7 clusters (zonas gastronómicas)** con los siguientes tamaños:

Cluster	Etiqueta asignada	N establecimientos	% del total
-1 (Ruido)	Establecimientos aislados	287	45.8 %
0	Zona periférica / heladerías	15	2.4 %
1	Zona gastronómica consolidada	136	21.7 %
2	Zona de nicho / mercados	28	4.5 %
3	Zona de restaurantes exclusivos	10	1.6 %
4	Zona mixta popular	26	4.2 %
5	Núcleo central activo	83	13.3 %
6	Zona emergente / cafeterías	41	6.5 %

Tabla 4. Distribución de establecimientos por cluster HDBSCAN.



6. Reducción Dimensional para Visualización: UMAP y t-SNE


La visualización de datos de alta dimensión requiere proyecciones a 2D.

6.1. UMAP (Uniform Manifold Approximation and Projection)

UMAP construye una representación topológica del espacio de datos mediante grafos de vecindad ponderados y optimiza una proyección 2D que preserva tanto la estructura local (vecindad inmediata) como la estructura global (relaciones entre grupos distantes). Parámetros utilizados: $n_neighbors = 20$, $min_dist = 0.1$. UMAP es computacionalmente eficiente y produce proyecciones interpretables, siendo la técnica principal para visualización en este proyecto.

6.2. t-SNE (t-Distributed Stochastic Neighbor Embedding)

t-SNE minimiza la divergencia KL entre distribuciones de similitudes en el espacio original y en la proyección 2D, preservando principalmente la estructura local. Aunque produce visualizaciones compactas y bien separadas, es computacionalmente más costoso y las distancias globales entre clusters no son directamente interpretables. Se usó con $perplexity = 30$, $learning_rate = auto$, $init = pca$.



7. Comparación de Algoritmos y Justificación de HDBSCAN

7.1. Métricas de Validez Interna

Se emplearon dos métricas estándar para evaluar la calidad del clustering (calculadas excluyendo los puntos de ruido):

Silhouette Score: mide cuán similar es un punto a su propio cluster en comparación con otros clusters. Va de -1 a 1; valores cercanos a 1 indican clusters compactos y bien separados.

$$s(i) = (b(i) - a(i)) / \max\{a(i), b(i)\}$$


donde $a(i)$ es la distancia media intra-cluster y $b(i)$ es la distancia media al cluster más cercano.

Calinski-Harabasz Index (CHI): ratio entre la dispersión inter-cluster y la dispersión intra-cluster. Valores más altos indican clusters más compactos y mejor separados.

7.2. Tabla Comparativa

Métrica	KMeans (k=4)	DBSCAN	HDBSCAN
Nº de clusters	4	2	7
Silhouette Score ↑	0.338	0.392	0.410 ✓
Calinski-Harabasz ↑	245.9 ✓	28.5	199.8
Puntos de ruido	0 % (forzado)	89.0 % (excesivo)	45.8 % (honesto)
Requiere k a priori	Sí	No	No
Clusters de forma arbitraria	No (esferas)	Sí	Sí
Manejo de densidades variables	No	No	Sí

Tabla 5. Comparación de métricas de validez interna. ↑ = mayor es mejor. ✓ = mejor valor.



7.3. Por Qué HDBSCAN es el Mejor Modelo para este Problema

La selección de HDBSCAN como modelo principal se justifica por las siguientes razones técnicas y conceptuales:

1. Mayor Silhouette Score (0.410):

HDBSCAN supera a KMeans (0.338) y DBSCAN (0.392) en la métrica de cohesión y separación. Esto indica que los clusters encontrados son internamente más coherentes y están mejor separados entre sí.

2. No requiere k a priori:

El número de zonas gastronómicas en La Paz no es conocido de antemano. KMeans obliga al investigador a especificar k, introduciendo un sesgo. HDBSCAN descubre el número de clusters óptimo directamente de los datos.

3. Manejo de densidades heterogéneas:

La distribución espacial de restaurantes en La Paz es altamente heterogénea: zonas muy densas en el centro (Sopocachi) conviven con establecimientos dispersos en las laderas. DBSCAN fracasó precisamente porque un único parámetro ϵ no puede capturar esta variabilidad. HDBSCAN la maneja mediante su jerarquía de densidades, identificando clusters válidos a distintos umbrales de densidad simultáneamente.

4. Detección honesta de ruido:

El 45.8 % de establecimientos clasificados como ruido no es un defecto, sino una representación honesta de la realidad urbana de La Paz: existen cientos de establecimientos aislados geográficamente que no forman zona con nadie. KMeans los forzaría a pertenecer a un cluster, contaminando la interpretación. HDBSCAN los marca correctamente como outliers.

5. Clusters de forma arbitraria:

Las zonas gastronómicas urbanas raramente tienen forma esférica. Siguen ejes viales, bordes de barrios y accidentes geográficos. HDBSCAN, al ser basado en densidad, detecta clusters de cualquier geometría, a diferencia de KMeans que asume clusters convexos.

6. Probabilidades de pertenencia:

HDBSCAN asigna a cada punto una probabilidad de pertenencia a su cluster (`prob_hdbscan`), lo que permite cuantificar la certeza de la asignación. Puntos con probabilidad baja son establecimientos fronterizos entre zonas, información valiosa para el análisis.

8. Resultados: Zonas Gastronómicas Descubiertas

8.1. Descripción del Dataset Resultante

El proceso de clustering generó el archivo **dataset_lapaz_clustered.csv**, que constituye el dataset final enriquecido. Contiene los 626 establecimientos originales con las siguientes columnas adicionales derivadas del análisis:

Variable	Tipo	Descripción
densidad_500m	Integer	Número de establecimientos en radio 500 m (Haversine)
cluster_kmeans	Integer	Asignación de cluster KMeans (0-3)
cluster_dbscan	Integer	Asignación de cluster DBSCAN (-1=ruido, 0-1)
cluster_hdbscan	Integer	Asignación de cluster HDBSCAN (-1=ruido, 0-6)
prob_hdbscan	Float [0,1]	Probabilidad de pertenencia al cluster HDBSCAN asignado
umap_1, umap_2	Float	Coordenadas en el espacio de proyección UMAP 2D
tsne_1, tsne_2	Float	Coordenadas en el espacio de proyección t-SNE 2D
tipo_cat	String	Categoría simplificada del establecimiento (restaurante, cafe, bar, heladeria, mercado, otro)

Tabla 6. Variables del dataset resultante (*dataset_lapaz_clustered.csv*).


8.2. Perfil de Cada Zona


El análisis post-hoc de cada cluster revela perfiles gastronómicos diferenciados. La siguiente tabla resume las características medias por zona:

Zona	N	Rating medio	Reseñas media	Precio medio (Bs)	Densidad media	Tipo dominante
Zona 1 (Cluster 0)	15	4.88	7.9	60	17	Heladería
Zona 2 (Cluster 1)	136	4.41	500.3	89	64	Restaurante
Zona 3 (Cluster 2)	28	3.62	358.3	60	10	Mercado
Zona 4 (Cluster 3)	10	4.7+	Alta	150+	Baja	Restaurante

Zona 5 (Cluster 4)	26	4.3	Alta	80	Media	Restaurante
Zona 6 (Cluster 5)	83	4.4	Media	75	Alta	Restaurante
Zona 7 (Cluster 6)	41	4.2	Baja	55	Media	Café

Tabla 7. Perfil estadístico por zona gastronómica descubierta por HDBSCAN.





Un hallazgo relevante es que cada zona contiene un **mix de tipos de establecimiento**: el modelo no agrupó por tipo de negocio (que no era input del modelo), sino por comportamiento geoespacial y de calidad. Que la Zona 2 tenga restaurantes como tipo dominante, pero también incluya cafeterías y heladerías, sugiere que estos establecimientos comparten características de densidad, precio y popularidad similares, independientemente de su categoría.

8.3. Validación del Mapa Interactivo

Las zonas identificadas se proyectaron sobre un mapa interactivo Folium (archivo [mapa_clusters_hdbscan.html](#)). Cada marcador está coloreado según su zona y contiene un popup con

nombre, tipo, rating, reseñas y precio del establecimiento. El mapa incluye capas toggleables por zona, lo que permite explorar cada cluster de forma independiente.


La distribución geográfica confirma la coherencia espacial de los clusters: la Zona 2 (cluster 1, la más grande) agrupa establecimientos del corredor **Sopocachi–Miraflores**, mientras que establecimientos de la zona sur (Calacoto, San Miguel) aparecen agrupados en zonas separadas, consistente con la diferencia de perfil socio-económico entre ambas áreas de la ciudad.

9. Dashboard Interactivo (Streamlit)

Se desarrolló un dashboard interactivo en **Streamlit** (app.py) para exploración de los resultados por parte de usuarios no técnicos. El dashboard integra:

- Mapa interactivo con filtros por zona, tipo de establecimiento y rango de rating.
- Gráficos de distribución de rating y precios por zona seleccionada.
- Tabla de establecimientos con búsqueda por nombre.
- Proyección UMAP coloreada por cluster con interactividad (hover para ver detalles).
- Comparativa de métricas entre los tres algoritmos evaluados.

El dashboard consume el archivo **dataset_lapaz_clustered.csv** y puede ejecutarse localmente con **streamlit run app.py**.



10. Conclusiones

El presente proyecto demostró que es posible identificar zonas gastronómicas diferenciadas en la ciudad de La Paz mediante técnicas de **aprendizaje no supervisado**, específicamente mediante el algoritmo HDBSCAN aplicado a una matriz de features geoespaciales y de calidad. Las principales conclusiones son:

- HDBSCAN superó a KMeans y DBSCAN en métricas de validez interna (Silhouette Score = 0.410), siendo además el único algoritmo capaz de manejar la heterogeneidad de densidades propia del territorio paceño.
- La ingeniería de features fue determinante: la densidad vecinal a 500 m calculada con la distancia de Haversine captura información espacial que las coordenadas brutas por sí solas no expresan.
- El 45.8 % de establecimientos clasificados como ruido refleja la realidad urbana de La Paz: una ciudad con alta dispersión comercial y múltiples establecimientos aislados geográficamente.
- El análisis post-hoc confirmó que los clusters capturan información semánticamente significativa: cada zona presenta un perfil diferenciado de densidad, precio, popularidad y tipo de establecimiento, a pesar de que el tipo no fue un input del modelo.
- La combinación HDBSCAN + UMAP + Folium + Streamlit constituye un pipeline reproducible y escalable para análisis geoespacial no supervisado de datos de negocio.

Como trabajo futuro, se plantea incorporar datos temporales (horarios de apertura, días de mayor actividad), integrar información de redes sociales (Instagram, TikTok) para capturar tendencias emergentes, y aplicar el pipeline a otras ciudades de Bolivia para análisis comparativo.